

Computational Astrophysics

Observatorio Astronómico Nacional

Observatorio Astronómico Nacional de Colombia

Astronomical Institute of the Czech Academy of Sciences

Regresión

Dr. rer. nat. Jose Ivan Campos Rozo

Hvar Observatory, Faculty of Geodesy - Zagreb, Croatia
Observatorio Astrónomico Nacional de Colombia - UNAL

September 19, 2026

Astrofísica Computacional

CONTENIDO

1. Introducción
   - Problemas físicos donde usamos regresión
   - Método de mínimos cuadrados

CONTENIDO

1. Introducción
   - Problemas físicos donde usamos regresión
   - Método de mínimos cuadrados
2. Regresión
   - Regresión lineal sin intercepto
   - Regresión lineal generalizada
   - Regresión no lineal

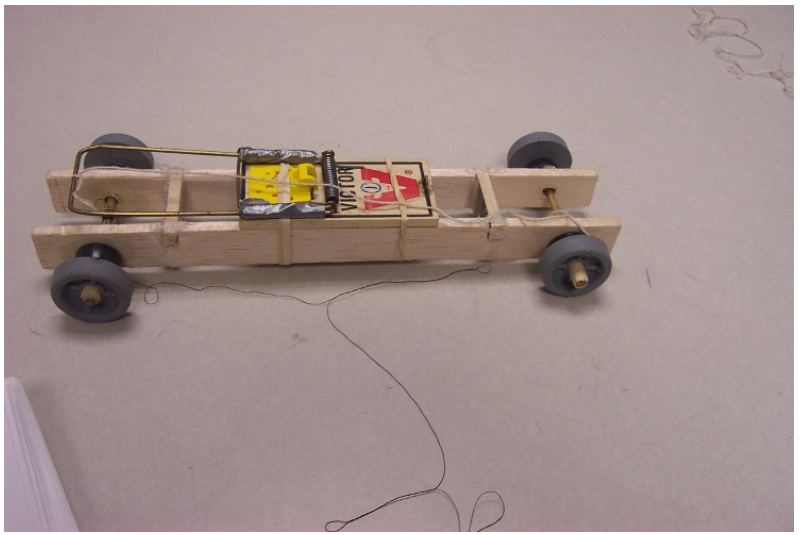
Problema del carro "ratonera"

Un estudiante quiere construir un coche con trampa para ratones que vaya más rápido o más lejos.

Se supone que la relación entre el par motor (T) y el ángulo de rotación (θ) es una línea recta:

$$T = k_0 + k_1\theta$$

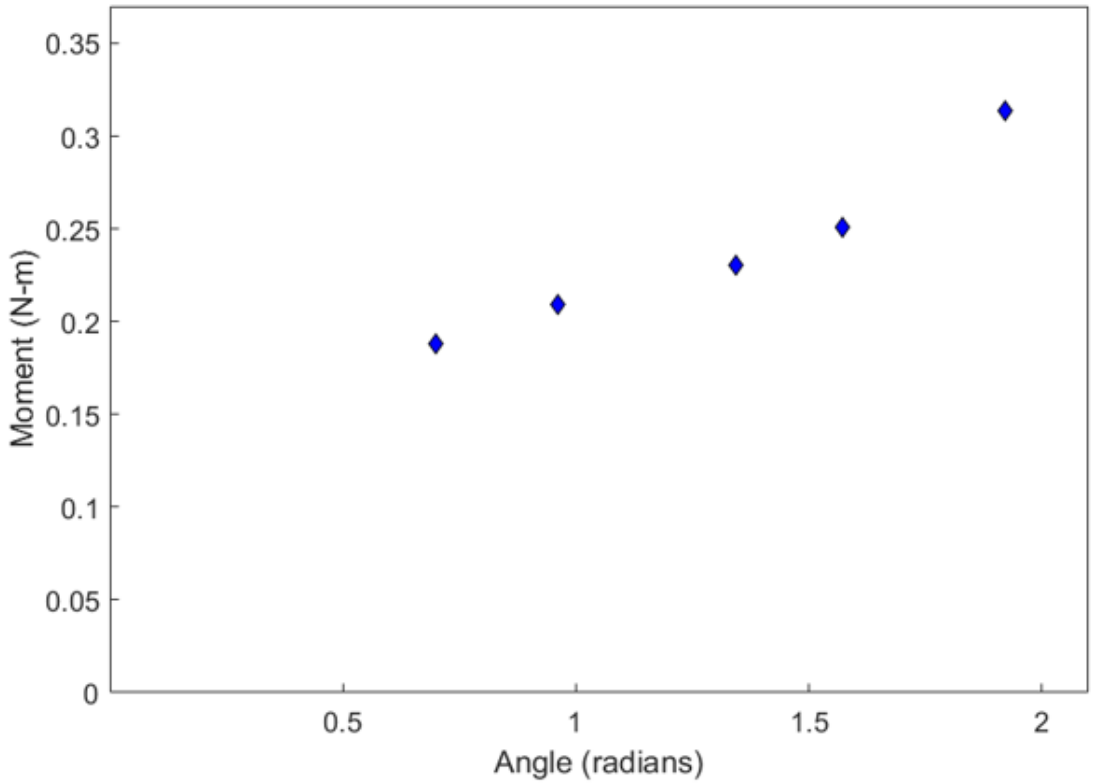
donde k_1 es la constante elástica.



Problema del carro "ratonera"

Se mide con instrumentos de laboratorio el torque para diferentes ángulos del resorte de la trampa de ratón y se tiene

Angle	Torque
Radians	N-m
0.698132	0.188224
0.959931	0.209138
1.134464	0.230052
1.570796	0.250965
1.919862	0.313707



Método de mínimos cuadrados

Para un conjunto dado de n pares de datos $(x_1, y_1), \ldots, (x_n, y_n)$, buscamos ajustar un modelo $y = a_0 + a_1 x$.

Método de mínimos cuadrados

Para un conjunto dado de n pares de datos $(x_1, y_1), \ldots, (x_n, y_n)$, buscamos ajustar un modelo $y = a_0 + a_1 x$.

El residuo E_i en cada punto de datos es la diferencia entre los valores observados y predichos:

$$E_i = y_i - (a_0 + a_1 x_i)$$

Método de mínimos cuadrados

Para un conjunto dado de n pares de datos $(x_1, y_1), \ldots, (x_n, y_n)$, buscamos ajustar un modelo $y = a_0 + a_1 x$.

El residuo E_i en cada punto de datos es la diferencia entre los valores observados y predichos:

$$E_i = y_i - (a_0 + a_1 x_i)$$

El método de mínimos cuadrados minimiza la suma de los residuos al cuadrado (S_r):

$$S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - a_0 - a_1 x_i)^2$$

.

Método de mínimos cuadrados

La solución para las constantes a_0 y a_1 están dadas por

$$a_0 = \frac{\sum_{i=1}^{n} y_i \sum_{i=1}^{n} x_i^2 - \sum_{i=1}^{n} x_i \sum_{i=1}^{n} x_i y_i}{n \sum_{i=1}^{n} x_i^2 - \left(\sum_{i=1}^{n} x_i \right)^2}$$

$$a_1 = \frac{n \sum_{i=1}^{n} x_i y_i - \sum_{i=1}^{n} x_i \sum_{i=1}^{n} y_i}{n \sum_{i=1}^{n} x_i^2 - \left(\sum_{i=1}^{n} x_i \right)^2}$$

Método de mínimos cuadrados

La solución para las constantes a_0 y a_1 están dadas por

$$a_0 = \frac{\sum_{i=1}^{n} y_i \sum_{i=1}^{n} x_i^2 - \sum_{i=1}^{n} x_i \sum_{i=1}^{n} x_i y_i}{n \sum_{i=1}^{n} x_i^2 - \left(\sum_{i=1}^{n} x_i \right)^2}$$

$$a_1 = \frac{n \sum_{i=1}^{n} x_i y_i - \sum_{i=1}^{n} x_i \sum_{i=1}^{n} y_i}{n \sum_{i=1}^{n} x_i^2 - \left(\sum_{i=1}^{n} x_i \right)^2}$$

donde a_0 se puede reescribir como

$$\begin{aligned} a_0 &= \frac{\sum_{i=1}^{n} y_i}{n} - a_1 \frac{\sum_{i=1}^{n} x_i}{n} \\ &= \overline{y} - a_1 \overline{x} \end{aligned}$$

Regresión lineal sin intercepto

Sea el conjunto de datos $(x_1, y_1), \ldots, (x_n, y_n)$, entonces lo ajustamos con el modelo

$$y = a_1 x$$

Regresión lineal sin intercepto

Sea el conjunto de datos $(x_1, y_1), \ldots, (x_n, y_n)$, entonces lo ajustamos con el modelo

$$y = a_1 x$$

Una buena medida de ajuste, es decir, qué tan bien $a_1 x$ predice la variable y, es la suma de los cuadrados de los residuos, S_r

$$S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - a_1 x_i)^2$$

Regresión lineal sin intercepto

Sea el conjunto de datos $(x_1, y_1), \ldots, (x_n, y_n)$, entonces lo ajustamos con el modelo

$$y = a_1 x$$

Una buena medida de ajuste, es decir, qué tan bien $a_1 x$ predice la variable y, es la suma de los cuadrados de los residuos, S_r

$$S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - a_1 x_i)^2$$

Para encontrar a_1, revisamos para que valor de a_1, S_r alcanza el mínimo absoluto tal que

$$\frac{\mathrm{d}S_r}{\mathrm{d}a_1} = 2\sum_{i=1}^{n}(y_i - a_1 x_i)(-x_i) = -2\sum_{i=1}^{n} y_i x_i + 2a_1 \sum_{i=1}^{n} x_i^2 = 0$$

Regresión lineal sin intercepto

De ahí tenemos que

$$a_1 = \frac{\sum_{i=1}^{n} x_i y_i}{\sum_{i=1}^{n} x_i^2}$$

Regresión lineal sin intercepto

De ahí tenemos que

$$a_1 = \frac{\sum_{i=1}^{n} x_i y_i}{\sum_{i=1}^{n} x_i^2}$$

Si se hace un test de la segunda derivada tenemos que

$$\frac{\mathrm{d}^2 S_r}{\mathrm{d}a_1^2} = \sum_{i=1}^{n} 2x_i^2 > 0$$

Regresión lineal sin intercepto

De ahí tenemos que

$$a_1 = \frac{\sum_{i=1}^{n} x_i y_i}{\sum_{i=1}^{n} x_i^2}$$

Si se hace un test de la segunda derivada tenemos que

$$\frac{\mathrm{d}^2 S_r}{\mathrm{d}a_1^2} = \sum_{i=1}^{n} 2x_i^2 > 0$$

Asumiendo que todos los valores de x son diferentes de cero, se puede afirmar que a_1, no solo es un mínimo local, sino un mínimo absoluto.

Ejemplo

Hallar el módulo longitudinal de un material compuesto, usando los siguientes datos. Dado que el módulo longitudinal está dado por $\sigma = E\varepsilon$

Deformación (ε)	Estrés [Pa] (σ)
0.0	0.0
1.83×10^{-3}	3.06×10^{8}
3.6×10^{-3}	6.12×10^{8}
5.324×10^{-3}	9.17×10^{8}
7.02×10^{-3}	1.223×10^{9}
8.67×10^{-3}	1.529×10^{9}
1.0244×10^{-2}	1.835×10^{9}
1.1774×10^{-2}	2.14×10^{9}
1.329×10^{-2}	2.446×10^{9}
1.479×10^{-2}	2.752×10^{9}
1.5×10^{-2}	2.767×10^{9}
1.56×10^{-2}	2.896×10^{9}

Ejemplo

Dada la forma $y = a_1 x$, y $a_1 = \frac{\sum_{i=1}^{n} x_i y_i}{\sum_{i=1}^{n} x_i^2}$, tenemos que

$$E = \frac{\sum_{i=1}^{n} \sigma_i \varepsilon_i}{\sum_{i=1}^{n} \varepsilon_i^2}$$

Ejemplo

Dada la forma $y = a_1 x$, y $a_1 = \frac{\sum_{i=1}^{n} x_i y_i}{\sum_{i=1}^{n} x_i^2}$, tenemos que

$$E = \frac{\sum_{i=1}^{n} \sigma_i \varepsilon_i}{\sum_{i=1}^{n} \varepsilon_i^2}$$

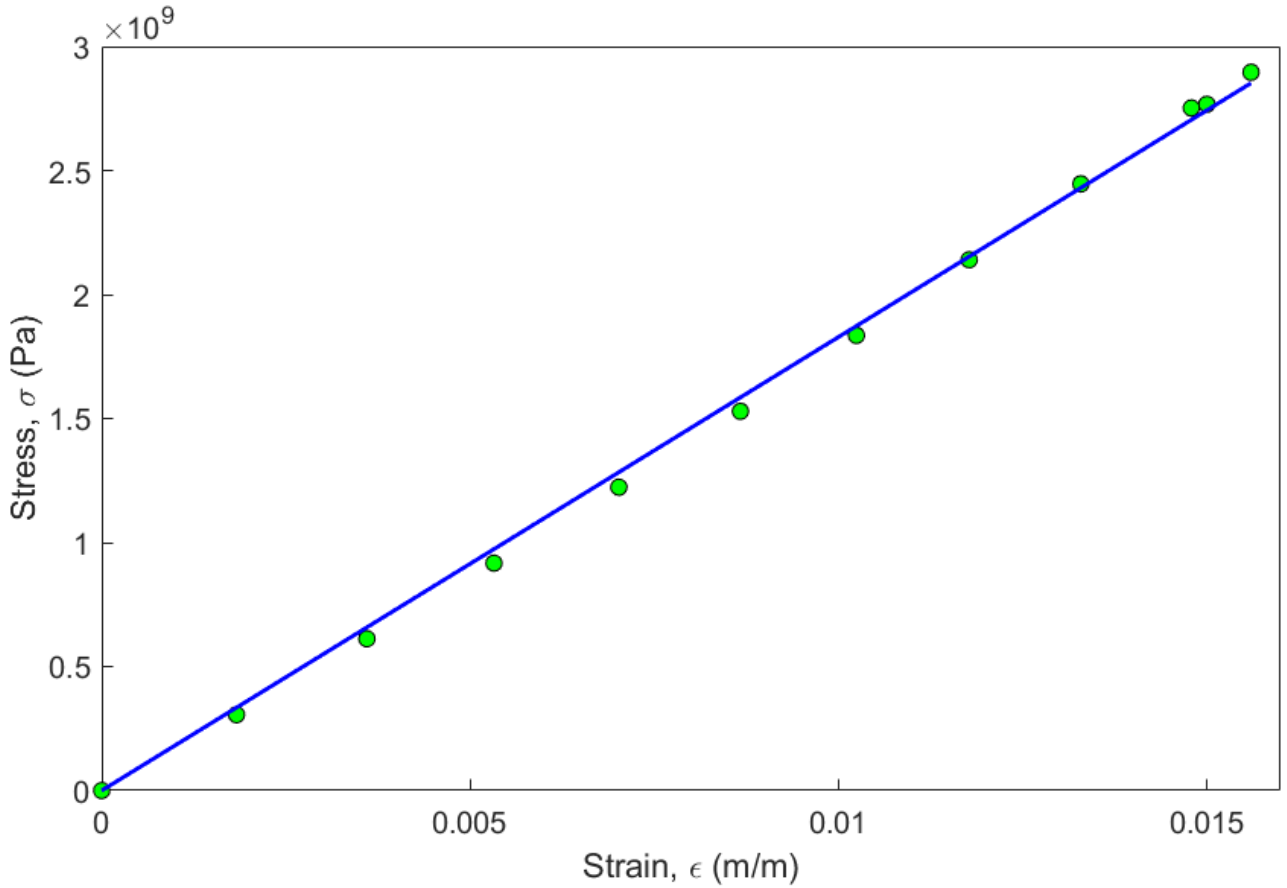
si $n = 12$, entonces

$$\sum_{i=1}^{12} \varepsilon_i^2 = 1.2764 \times 10^{-3}; \quad \sum_{i=1}^{12} \sigma_i \varepsilon_i = 2.3337 \times 10^{8},$$

$$E = \frac{\sum_{i=1}^{12} \sigma_i \varepsilon_i}{\sum_{i=1}^{12} \varepsilon_i^2} = \frac{2.3337 \times 10^{8}}{1.2764 \times 10^{-3}} = 1.8284 \times 10^{11} Pa$$

Ejemplo

Por lo tanto tenemos que nuestra ecuación de la recta está dada por $\sigma = 1.8282 \times 10^{11}\varepsilon$



Regresión lineal generalizada

Teniendo que $y = a_0 + a_1 x$ para un conjunto de datos de n puntos. Y recordando que

$$S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - a_0 - a_1 x)^2$$

Regresión lineal generalizada

Teniendo que $y = a_0 + a_1 x$ para un conjunto de datos de n puntos. Y recordando que

$$S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - a_0 - a_1 x)^2$$

Y haciendo un poco de algebra como en el caso anterior, encontramos que

$$a_1 = \frac{S_{xy}}{S_{xx}}; \qquad a_0 = \overline{y} - a_1 \overline{x}$$

Regresión lineal generalizada

Teniendo que $y = a_0 + a_1 x$ para un conjunto de datos de n puntos. Y recordando que

$$S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - a_0 - a_1 x)^2$$

Y haciendo un poco de algebra como en el caso anterior, encontramos que

$$a_1 = \frac{S_{xy}}{S_{xx}}; \qquad a_0 = \overline{y} - a_1 \overline{x}$$

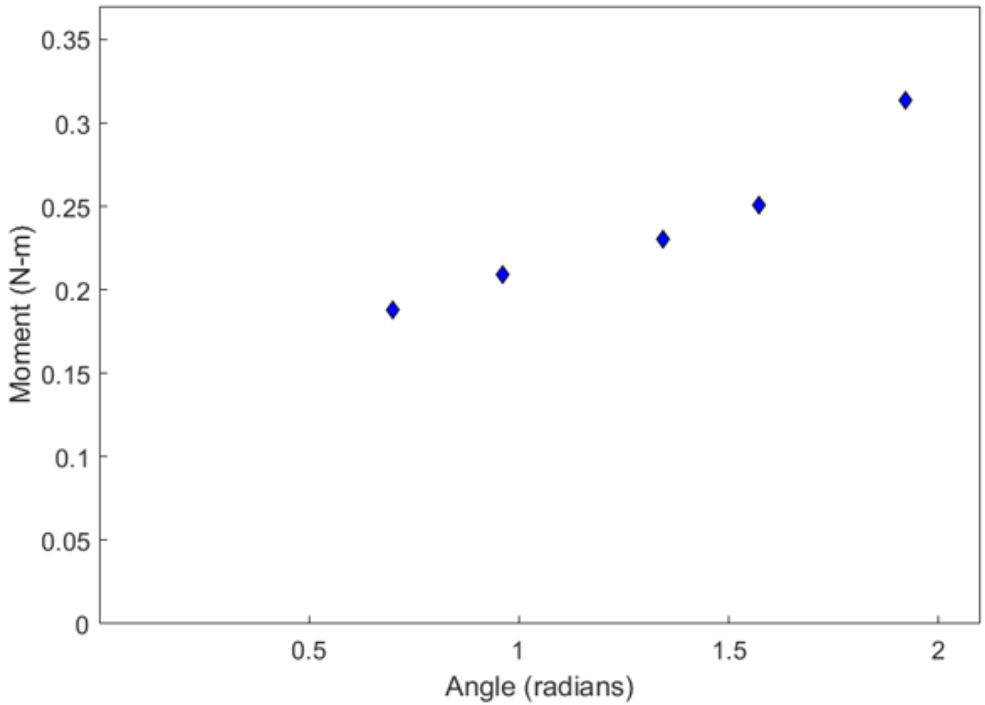
donde

$$S_{xy} = \sum_{i=1}^{n} x_i y_i - n\overline{x}\,\overline{y};\ S_{xx} = \sum_{i=1}^{n} x_i^2 - n\overline{x}^2;\ \overline{x} = \frac{\sum_{i=1}^{n} x_i}{n},\ \overline{y} = \frac{\sum_{i=1}^{n} y_i}{n}$$

Tarea en clase

Volviendo al carrito "ratonera", se mide con instrumentos de laboratorio el torque para diferentes ángulos del resorte de la trampa de ratón y se tiene

Angle	Torque
Radians	N-m
0.698132	0.188224
0.959931	0.209138
1.134464	0.230052
1.570796	0.250965
1.919862	0.313707



Encuentre las constantes k_1 y k_2 dada la ecuación $T = k_1 + k_2\theta$

Regresión no lineal

Muchos fenómenos físicos presentan una relación no lineal entre variables.

Regresión no lineal

Muchos fenómenos físicos presentan una relación no lineal entre variables.

El planteamiento del problema no lineal es el mismo

$$E_i = y_i - f(x_i); \quad S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - f(x))^2$$

Regresión no lineal

Muchos fenómenos físicos presentan una relación no lineal entre variables.

El planteamiento del problema no lineal es el mismo

$$E_i = y_i - f(x_i); \quad S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - f(x))^2$$

Existen muchos modeos no-lineales básicos en ciencia:

Regresión no lineal

Muchos fenómenos físicos presentan una relación no lineal entre variables.

El planteamiento del problema no lineal es el mismo

$$E_i = y_i - f(x_i); \quad S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - f(x))^2$$

Existen muchos modeos no-lineales básicos en ciencia:

- Modelo exponencial: $f(x) = ae^{bx}$

Regresión no lineal

Muchos fenómenos físicos presentan una relación no lineal entre variables.

El planteamiento del problema no lineal es el mismo

$$E_i = y_i - f(x_i); \quad S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - f(x))^2$$

Existen muchos modeos no-lineales básicos en ciencia:

- Modelo exponencial: $f(x) = ae^{bx}$
- Modelo de potencia: $f(x) = ax^b$

Regresión no lineal

Muchos fenómenos físicos presentan una relación no lineal entre variables.

El planteamiento del problema no lineal es el mismo

$$E_i = y_i - f(x_i); \quad S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - f(x))^2$$

Existen muchos modeos no-lineales básicos en ciencia:

- Modelo exponencial: $f(x) = ae^{bx}$
- Modelo de potencia: $f(x) = ax^b$
- Modelo de crecimiento por saturación: $f(x) = \frac{ax}{b+x}$

Regresión no lineal

Muchos fenómenos físicos presentan una relación no lineal entre variables.

El planteamiento del problema no lineal es el mismo

$$E_i = y_i - f(x_i); \quad S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - f(x))^2$$

Existen muchos modeos no-lineales básicos en ciencia:

- Modelo exponencial: $f(x) = ae^{bx}$
- Modelo de potencia: $f(x) = ax^b$
- Modelo de crecimiento por saturación: $f(x) = \frac{ax}{b+x}$
- Modelo harmónico descendente: $f(x) = \frac{b}{1+ax}$

Regresión no lineal

Muchos fenómenos físicos presentan una relación no lineal entre variables.

El planteamiento del problema no lineal es el mismo

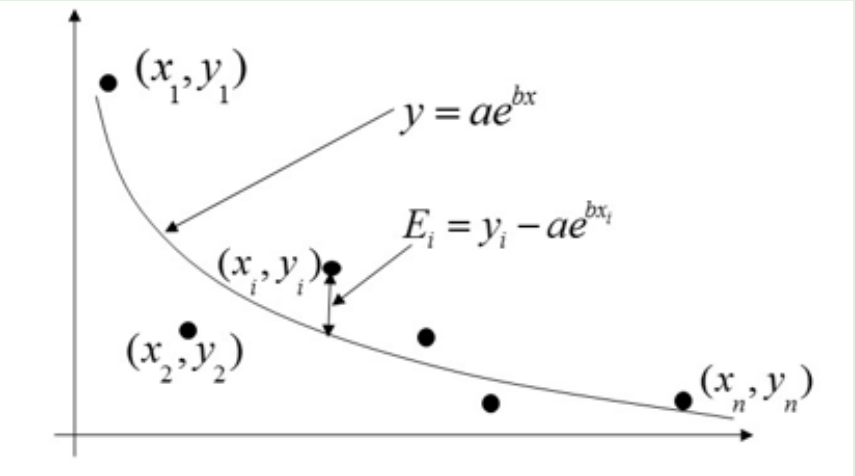
$$E_i = y_i - f(x_i); \quad S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - f(x))^2$$

Existen muchos modeos no-lineales básicos en ciencia:

- Modelo exponencial: $f(x) = ae^{bx}$
- Modelo de potencia: $f(x) = ax^b$
- Modelo de crecimiento por saturación: $f(x) = \frac{ax}{b+x}$
- Modelo harmónico descendente: $f(x) = \frac{b}{1+ax}$
- Modelos polinómicos: $f(x) = a_0 + a_1 x + ... + a_m x^m, \ \ m < n$

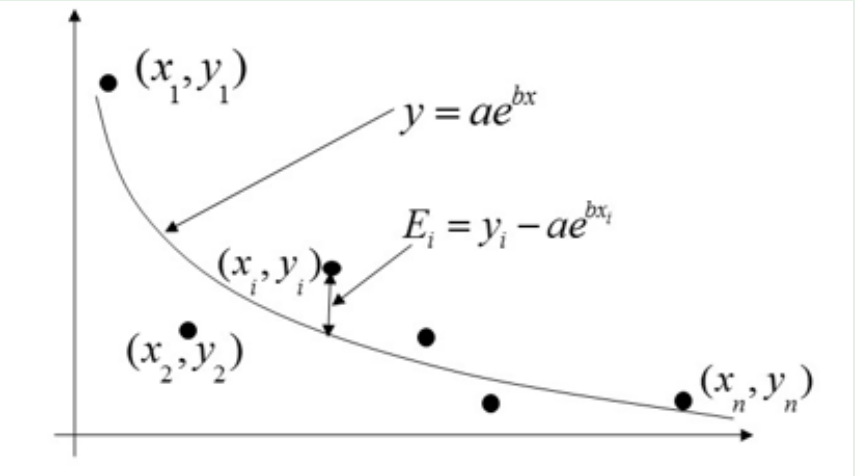
Modelo exponencial

Dado un conjunto de puntos $(x_1, y_1), (x_2, y_2), ..., (x_n, y_n)$, tal que el mejor ajuste está dado por ae^{bx}.



Modelo exponencial

Dado un conjunto de puntos $(x_1, y_1), (x_2, y_2), ..., (x_n, y_n)$, tal que el mejor ajuste está dado por ae^{bx}.



Donde las variables a y b son constantes en el modelo exponencial. E_i son los residuos en cada punto, tal que la suma de los residuos al cuadrado son

$$S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - ae^{bx_i})^2$$

Modelo exponencial

Para encontrar a y b, minimizamos diferenciando

$$\frac{\partial S_r}{\partial a} = \sum_{i=1}^{n} 2(y_i - ae^{bx_i})(-e^{bx_i}) = -2\sum_{i=1}^{n} y_i e^{bx_i} + 2\sum_{i=1}^{n} e^{2bx_i} = 0$$

$$\frac{\partial S_r}{\partial b} = \sum_{i=1}^{n} 2(y_i - ae^{bx_i})(-ax_i e^{bx_i}) = -2a\sum_{i=1}^{n} x_i y_i e^{bx_i} + 2a^2\sum_{i=1}^{n} x_i e^{2bx_i} = 0$$

Modelo exponencial

Para encontrar a y b, minimizamos diferenciando

$$\frac{\partial S_r}{\partial a} = \sum_{i=1}^{n} 2(y_i - ae^{bx_i})(-e^{bx_i}) = -2\sum_{i=1}^{n} y_i e^{bx_i} + 2\sum_{i=1}^{n} e^{2bx_i} = 0$$

$$\frac{\partial S_r}{\partial b} = \sum_{i=1}^{n} 2(y_i - ae^{bx_i})(-ax_i e^{bx_i}) = -2a\sum_{i=1}^{n} x_i y_i e^{bx_i} + 2a^2\sum_{i=1}^{n} x_i e^{2bx_i} = 0$$

Podemos ver que para encontrar a y b. necesitamos resolver un sistema de ecuaciones no lineales, y se requieren métodos numéricos.

Modelo exponencial

Para encontrar a y b, minimizamos diferenciando

$$\frac{\partial S_r}{\partial a} = \sum_{i=1}^{n} 2(y_i - ae^{bx_i})(-e^{bx_i}) = -2\sum_{i=1}^{n} y_i e^{bx_i} + 2\sum_{i=1}^{n} e^{2bx_i} = 0$$

$$\frac{\partial S_r}{\partial b} = \sum_{i=1}^{n} 2(y_i - ae^{bx_i})(-ax_i e^{bx_i}) = -2a\sum_{i=1}^{n} x_i y_i e^{bx_i} + 2a^2\sum_{i=1}^{n} x_i e^{2bx_i} = 0$$

Podemos ver que para encontrar a y b. necesitamos resolver un sistema de ecuaciones no lineales, y se requieren métodos numéricos.

Ya que los sistemas lineales son más simples de resolver, es posible transformar algunos modelos no lineales de forma lineal, pero no todos se pueden transformar.

Modelo exponencial

Siguiendo el modelo ae^{bx}, aplicamos el logaritmo natural a ambos lados de la ecuación

$$\ln y = \ln a + bx$$

Modelo exponencial

Siguiendo el modelo ae^{bx}, aplicamos el logaritmo natural a ambos lados de la ecuación

$$\ln y = \ln a + bx$$

renombramos $\ln y = z$, $\ln a = a_0$ y $a_1 = b$, entonces tenemos

$$z = a_0 + a_1 x$$

Modelo exponencial

Siguiendo el modelo ae^{bx}, aplicamos el logaritmo natural a ambos lados de la ecuación

$$\ln y = \ln a + bx$$

renombramos $\ln y = z$, $\ln a = a_0$ y $a_1 = b$, entonces tenemos

$$z = a_0 + a_1 x$$

Solucionando a_1 y a_0

$$a_1 = \frac{n\sum_{i=1}^{n} x_i z_i - \sum_{i=1}^{n} x_i \sum_{i=1}^{n} z_i}{n\sum_{i=1}^{n} x_i^2 - \left(\sum_{i=1}^{n} x_i\right)^2}$$

$$a_0 = \overline{z} - a_1 \overline{x}$$

tal que $b = a_1$ y $a = e^{a_0}$

Tarea en clase

Curva de luz SN tipo Ia

La curva de luz tardía de una supernova tipo Ia está dominada por el decaimiento radiactivo del ^{56}Co a ^{56}Fe, el cual libera fotones gamma que son termalizados y reemitidos como luz óptica. Se ha medido el flujo relativo de la supernova en función del tiempo desde el máximo de brillo:

tiempo [días]	0	10	20	30	40	50
flujo relativo (L/L_0)	1.0	0.914	0.836	0.764	0.699	0.639

El flujo relativo está relacionado con el tiempo mediante la ecuación $L = Ae^{\lambda t}$.

Tarea en clase

Curva de luz SN tipo Ia

La curva de luz tardía de una supernova tipo Ia está dominada por el decaimiento radiactivo del ^{56}Co a ^{56}Fe, el cual libera fotones gamma que son termalizados y reemitidos como luz óptica. Se ha medido el flujo relativo de la supernova en función del tiempo desde el máximo de brillo:

tiempo [días]	0	10	20	30	40	50
flujo relativo (L/L_0)	1.0	0.914	0.836	0.764	0.699	0.639

El flujo relativo está relacionado con el tiempo mediante la ecuación $L = Ae^{\lambda t}$.

Usando la transformación de la exponencial

a) evaluar las constantes de regresión A y λ
b) vida media del ^{56}Co
c) el flujo relativo después de 100 días.

Modelo exponencial

Si no transformamos la función exponencial. Recordemos que

$$\frac{\partial S_r}{\partial a} = -\sum_{i=1}^{n} y_i e^{bx_i} + a\sum_{i=1}^{n} e^{2bx_i} = 0$$

$$\frac{\partial S_r}{\partial b} = -\sum_{i=1}^{n} x_i y_i e^{bx_i} + a\sum_{i=1}^{n} x_i e^{2bx_i} = 0$$

Modelo exponencial

Si no transformamos la función exponencial. Recordemos que

$$\frac{\partial S_r}{\partial a} = -\sum_{i=1}^{n} y_i e^{bx_i} + a\sum_{i=1}^{n} e^{2bx_i} = 0$$

$$\frac{\partial S_r}{\partial b} = -\sum_{i=1}^{n} x_i y_i e^{bx_i} + a\sum_{i=1}^{n} x_i e^{2bx_i} = 0$$

De $\frac{\partial S_r}{\partial a}$ se puede obtener a explicitamente en términos de b

$$a = \frac{\sum_{i=1}^{n} y_i e^{bx_i}}{\sum_{i=1}^{n} e^{2bx_i}}$$

Modelo exponencial

Si no transformamos la función exponencial. Recordemos que

$$\frac{\partial S_r}{\partial a} = -\sum_{i=1}^{n} y_i e^{bx_i} + a\sum_{i=1}^{n} e^{2bx_i} = 0$$

$$\frac{\partial S_r}{\partial b} = -\sum_{i=1}^{n} x_i y_i e^{bx_i} + a\sum_{i=1}^{n} x_i e^{2bx_i} = 0$$

De $\frac{\partial S_r}{\partial a}$ se puede obtener a explicitamente en términos de b

$$a = \frac{\sum_{i=1}^{n} y_i e^{bx_i}}{\sum_{i=1}^{n} e^{2bx_i}}$$

y reemplazando a en $\frac{\partial S_r}{\partial b}$

$$\sum_{i=1}^{n} x_i y_i e^{bx_i} - \frac{\sum_{i=1}^{n} y_i e^{bx_i}}{\sum_{i=1}^{n} e^{2bx_i}} \sum_{i=1}^{n} x_i e^{2bx_i}$$

pero sigue sin ser lineal. Solución: métodos númericos, como bisección o secante.

Tarea semanal

Ejercicio 1

Usando los mismos datos de la tabla, responder las mismas preguntas en el ejemplo.

tiempo [días]	0	10	20	30	40	50
flujo relativo (L/L_0)	1.0	0.914	0.836	0.764	0.699	0.639

a) evaluar las constantes de regresión A y λ

b) vida media del ^{56}Co

c) el flujo relativo después de 100 días.

Modelos polinomiales

Dado un conjunto de datos $(x_1, y_1), (x_2, y_2), ..., (x_n, y_n)$, usar método de mínimos cuadrados para hacer regresión de los datos a un polinomio de orden m

$$y = a_0 + a_1 x + a_2 x^2 + ... + a_m x^m, \quad m < n$$

Modelos polinomiales

Dado un conjunto de datos $(x_1, y_1), (x_2, y_2), ..., (x_n, y_n)$, usar método de mínimos cuadrados para hacer regresión de los datos a un polinomio de orden m

$$y = a_0 + a_1 x + a_2 x^2 + ... + a_m x^m, \quad m < n$$

Tenemos entonces que

$$S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - a_0 - a_1 x_i - a_2 x_i^2 - ... - a_m x_i^m)^2$$

Modelos polinomiales

Dado un conjunto de datos $(x_1, y_1), (x_2, y_2), ..., (x_n, y_n)$, usar método de mínimos cuadrados para hacer regresión de los datos a un polinomio de orden m

$$y = a_0 + a_1 x + a_2 x^2 + ... + a_m x^m, \quad m < n$$

Tenemos entonces que

$$S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - a_0 - a_1 x_i - a_2 x_i^2 - ... - a_m x_i^m)^2$$

Para encontrar las constante $a_0, a_1, ..., a_m$, minimizamos tal que

$$\frac{\partial S_r}{\partial a_0} = \sum_{i=1}^{n} 2(y_i - a_0 - a_1 x_i - ... - a_m x_i^m)(-1) = 0$$

$$\frac{\partial S_r}{\partial a_1} = \sum_{i=1}^{n} 2(y_i - a_0 - a_1 x_i - ... - a_m x_i^m)(-x_i) = 0$$

$$\vdots = \vdots$$

$$\frac{\partial S_r}{\partial a_m} = \sum_{i=1}^{n} 2(y_i - a_0 - a_1 x_i - ... - a_m x_i^m)(-x_i^m) = 0$$

Modelos polinomiales

Reescribiendo en forma matricial

$$\begin{bmatrix} n & \sum_{i=1}^{n} x_i & \cdots & \sum_{i=1}^{n} x_i^m \\ \sum_{i=1}^{n} x_i & \sum_{i=1}^{n} x_i^2 & \cdots & \sum_{i=1}^{n} x_i^{m+1} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^{n} x_i^m & \sum_{i=1}^{n} x_i^{m+1} & \cdots & \sum_{i=1}^{n} x_i^{2m} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^{n} y_i \\ \sum_{i=1}^{n} x_i y_i \\ \vdots \\ \sum_{i=1}^{n} x_i^m y_i \end{bmatrix}$$

Este sistema de ecuaciones resuleve las constantes $a_0, a_1, a_2, ..., a_m$.

Ejemplo

Encontrar la contracción de un cilindro de acero. Para eso uno hace regresión el coeficiente de expansión térmica lineal con respecto a la temperatura.

- Ajustar los datos de la tabla a la función

$\alpha = a_0 + a_1 T + a_2 T^2$

temperatura (^oC)	coeficiente ($\alpha[1/^oC]$)
26.6	11.23×10^{-6}
4.4	10.3×10^{-6}
-40	9.16×10^{-6}
-84.4	11.65×10^{-6}
-128.9	7.74×10^{-6}
-173.3	5.99×10^{-6}
-206.7	4.41×10^{-6}

Table: Coeficiente de expansión térmica lineal a diferentes temperaturas

Solución

Usando la regresión, a_0, a_1 y a_2 están dados por

$$\begin{bmatrix} n & \sum_{i=1}^{n} T_i & \sum_{i=1}^{n} T_i^2 \\ \sum_{i=1}^{n} T_i & \sum_{i=1}^{n} T_i^2 & \sum_{i=1}^{n} T_i^3 \\ \sum_{i=1}^{n} T_i^2 & \sum_{i=1}^{n} T_i^3 & \sum_{i=1}^{n} T_i^4 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^{n} \alpha_i \\ \sum_{i=1}^{n} T_i \alpha_i \\ \sum_{i=1}^{n} T_i^2 \alpha_i \end{bmatrix}$$

donde $n = 7$.

Solución

Usando la regresión, a_0, a_1 y a_2 están dados por

$$\begin{bmatrix} n & \sum_{i=1}^{n} T_i & \sum_{i=1}^{n} T_i^2 \\ \sum_{i=1}^{n} T_i & \sum_{i=1}^{n} T_i^2 & \sum_{i=1}^{n} T_i^3 \\ \sum_{i=1}^{n} T_i^2 & \sum_{i=1}^{n} T_i^3 & \sum_{i=1}^{n} T_i^4 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^{n} \alpha_i \\ \sum_{i=1}^{n} T_i \alpha_i \\ \sum_{i=1}^{n} T_i^2 \alpha_i \end{bmatrix}$$

donde $n = 7$.

Haciendo todas las operaciones, obtenemos la matriz

$$\begin{bmatrix} 7 & -8.6 \times 10^2 & 2.58 \times 10^5 \\ -8.6 \times 10^2 & 2.58 \times 10^5 & -7.0472 \times 10^7 \\ 2.58 \times 10^5 & -7.0472 \times 10^7 & 2.1363 \times 10^{10} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 3.36 \times 10^{-5} \\ -2.6978 \times 10^{-3} \\ 8.5013 \times 10^{-1} \end{bmatrix}$$

Solución

Usando la regresión, a_0, a_1 y a_2 están dados por

$$\begin{bmatrix} n & \sum_{i=1}^{n} T_i & \sum_{i=1}^{n} T_i^2 \\ \sum_{i=1}^{n} T_i & \sum_{i=1}^{n} T_i^2 & \sum_{i=1}^{n} T_i^3 \\ \sum_{i=1}^{n} T_i^2 & \sum_{i=1}^{n} T_i^3 & \sum_{i=1}^{n} T_i^4 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^{n} \alpha_i \\ \sum_{i=1}^{n} T_i \alpha_i \\ \sum_{i=1}^{n} T_i^2 \alpha_i \end{bmatrix}$$

donde $n = 7$.

Haciendo todas las operaciones, obtenemos la matriz

$$\begin{bmatrix} 7 & -8.6 \times 10^2 & 2.58 \times 10^5 \\ -8.6 \times 10^2 & 2.58 \times 10^5 & -7.0472 \times 10^7 \\ 2.58 \times 10^5 & -7.0472 \times 10^7 & 2.1363 \times 10^{10} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 3.36 \times 10^{-5} \\ -2.6978 \times 10^{-3} \\ 8.5013 \times 10^{-1} \end{bmatrix}$$

Solucionando el sistema de ecuaciones, al final se optiene que $a_0 =?$, $a_1 =?$ y $a_2 =?$

Orden óptimo para una regresión polinomial

Supongamos que no se conocen otros modelos que el polinomial, aún así, uno se enfrenta al problema de qué orden es el más óptimo para ajustar los datos.

Orden óptimo para una regresión polinomial

Supongamos que no se conocen otros modelos que el polinomial, aún así, uno se enfrenta al problema de qué orden es el más óptimo para ajustar los datos.

Temperatura (^oF)	Coeficiente ($\mu(1/^oF)$)	Temperatura (^oF)	Coeficiente ($\mu(1/^oF)$)	Temperatura (^oF)	Coeficiente ($\mu(1/^oF)$)
80	6.47	-80	5.43	-240	3.83
60	6.36	-100	5.28	-260	3.58
40	6.24	-120	5.09	-280	3.33
20	6.12	-140	4.91	-300	3.07
0	6.0	-160	4.72	-320	2.76
-20	5.86	-180	4.52	-340	2.45
-40	5.72	-200	4.30		
-60	5.58	-220	4.08		

Orden óptimo para una regresión polinomial

Supongamos que no se conocen otros modelos que el polinomial, aún así, uno se enfrenta al problema de qué orden es el más óptimo para ajustar los datos.

Temperatura (^oF)	Coeficiente ($\mu(1/^oF)$)	Temperatura (^oF)	Coeficiente ($\mu(1/^oF)$)	Temperatura (^oF)	Coeficiente ($\mu(1/^oF)$)
80	6.47	-80	5.43	-240	3.83
60	6.36	-100	5.28	-260	3.58
40	6.24	-120	5.09	-280	3.33
20	6.12	-140	4.91	-300	3.07
0	6.0	-160	4.72	-320	2.76
-20	5.86	-180	4.52	-340	2.45
-40	5.72	-200	4.30		
-60	5.58	-220	4.08		

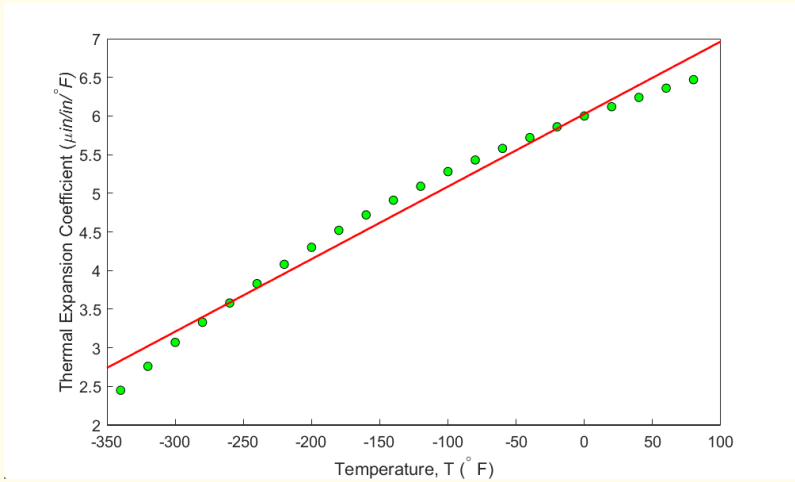


Figure: Regresión orden 1: $\alpha = 0.00938T + 6.025$

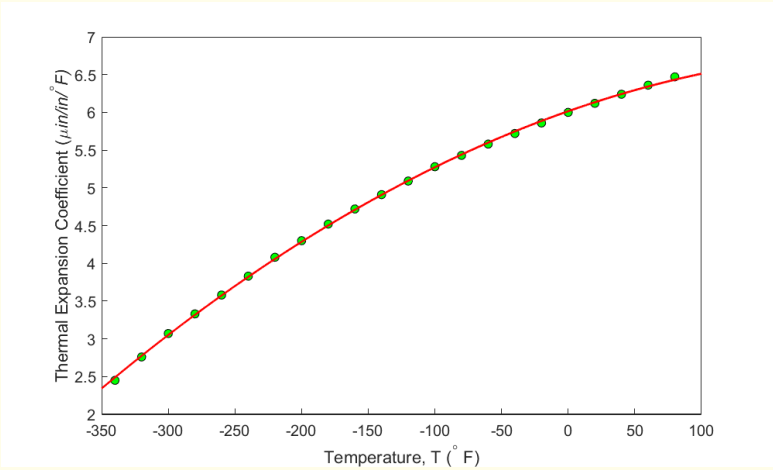


Figure: Regresión orden 2:
$\alpha = -1.228 \times 10^{-5}T^2 + 6.196 \times 10^{-3}T + 6.015$

Orden óptimo para una regresión polinomial

Orden óptimo para una regresión polinomial

Aunque visualmente es claro que el polinomio de segundo orden es aceptable, las decisiones deben basarse en medidas cuantificables.

Orden óptimo para una regresión polinomial

Aunque visualmente es claro que el polinomio de segundo orden es aceptable, las decisiones deben basarse en medidas cuantificables.

Uno de los criterios para elegir el grado del polinomio más óptimo, es la variancia dada por

$$\text{variance} = \frac{S_r}{n-(m+1)}$$

Orden óptimo para una regresión polinomial

Aunque visualmente es claro que el polinomio de segundo orden es aceptable, las decisiones deben basarse en medidas cuantificables.

Uno de los criterios para elegir el grado del polinomio más óptimo, es la variancia dada por

$$\text{variance} = \frac{S_r}{n-(m+1)}$$

Siguiendo este criterio, al final uno sí puede elegir de forma cuantitativa el orden del polinomio

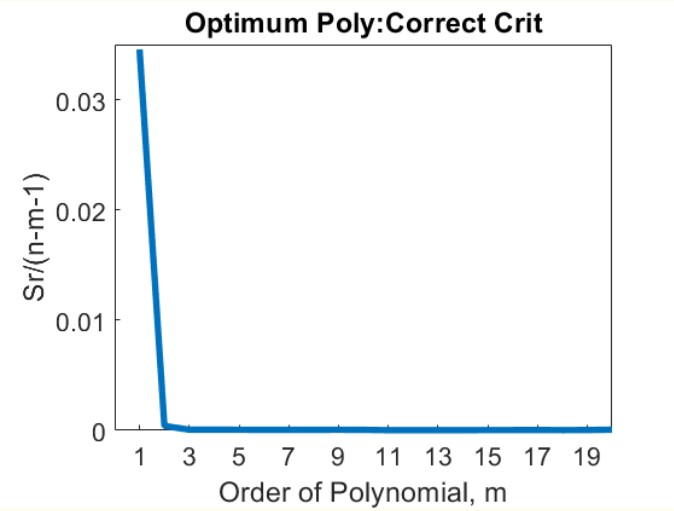
Orden óptimo para una regresión polinomial

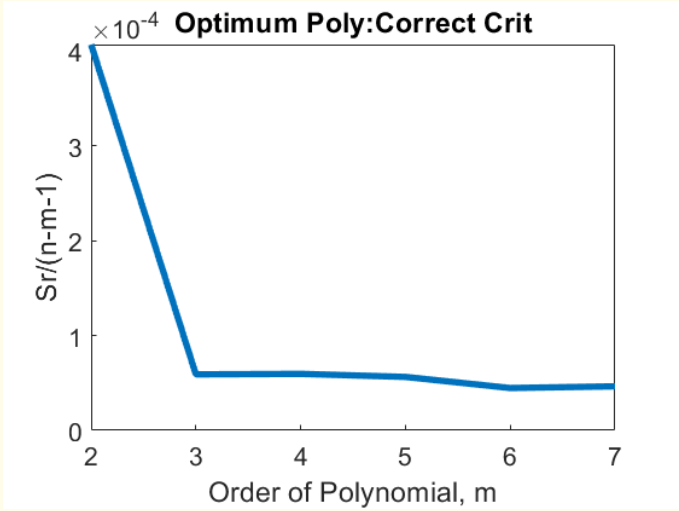
Aunque visualmente es claro que el polinomio de segundo orden es aceptable, las decisiones deben basarse en medidas cuantificables.

Uno de los criterios para elegir el grado del polinomio más óptimo, es la variancia dada por

$$\text{variance} = \frac{S_r}{n-(m+1)}$$

Siguiendo este criterio, al final uno sí puede elegir de forma cuantitativa el orden del polinomio





Y aún así, m debería ser 2 o 3?

Continuará

Dr. rer. nat. Jose Ivan Campos Rozo
jicamposr@unal.edu.co